

IABR-Net GPU Run — চূড়ান্ত বিশ্লেষণ রিপোর্ট

এই ডকুমেন্ট কী: IABR-Net-এর সম্পূর্ণ GPU test-suite রান (৩৭টা experiment, `_smoke_test: false`, মোট wall-clock $\approx$ ৩.৮ ঘণ্টা দুই session মিলিয়ে) থেকে পাওয়া প্রতিটা সংখ্যার একটা একক, verified, সংশোধিত সমন্বয়। এটা একটা multi-agent pipeline-এর চূড়ান্ত পণ্য: ছয়জন analyst (group report 01–06) → একজন MOTHER agent (07, সমন্বয়) → একজন adversarial VERIFIER (08, প্রতিটা সংখ্যা raw source-এর বিপরীতে হাতে-চেক) → একজন RESEARCH agent (09, literature-backed next-step) এই ফাইনাল রিপোর্টে **verifier**-এর ধরা তিনটা ভুল আর একটা **unverifiable claim** সংশোধন/চিহ্নিত করে দেওয়া হয়েছে (বিস্তারিত §৬-এ)।

০. কীভাবে পড়বে

এই রিপোর্ট একটা সমন্বিত সারসংক্ষেপ — পুরো detail (প্রতিটা JSON field, প্রতিটা code snippet, প্রতিটা derived হিসাবের method) ধরে না। নিচের group report-গুলোতে সেই আসল detail আছে, একই ফোল্ডারে (GPU_RUN_ANALYSIS/):

ফাইল	কী আছে
01_sanity_verification.md	E0a, BANKS_build, E0b, V0, V1 — পুরো pipeline বিশ্বাসযোগ্য কিনা তার প্রমাণ
02_training_indist_seeds.md	Training (3 seed), E3 headline SNR sweep, E11 multi-seed, SNR_tails extrapolation
03_impairment_robustness.md	E4 (phase), E5 (gain), E6 (OOD phase) — IABC-v2-এর মূল দাবির পরীক্ষা
04_scene_difficulty.md	E7 (path count), E8 (angular separation), E10 (nuisance path)
05_ablations_controls.md	Controls (E1/E2/Abl1/Abl3), Abl-2 (decode ablation), Abl-6 (loss-weight sweep)
06_efficiency.md	E9 — params/FLOPs/latency/memory
07_mother_synthesis.md	ছয়টা group report-এর সমন্বয় (cross-experiment pattern সহ)
08_verification.md	৩৩টা claim-এর numeric audit — ২৯ CORRECT, ৩ WRONG, ১ UNVERIFIABLE
09_next_steps_research.md	Literature-backed fix প্রস্তাব, real citation সহ

এই ফাইনাল রিপোর্ট 07 থেকে headline নিয়ে, 08-এর সংশোধন প্রয়োগ করে, আর 01–06-এর detail দিয়ে প্রতিটা experiment-কে সম্পূর্ণ করে বানানো। কোনো নতুন সংখ্যা এখানে আবিষ্কার করা হয়নি — সব কিছু উপরের ৯টা ফাইল থেকে হুবহু নেওয়া বা তাদের রিপোর্ট করা derived হিসাব।

১. সংক্ষেপে (Executive Summary)

IABR-Net কি সফল? সংক্ষেপে: আংশিকভাবে সফল — **parameter/FLOP efficiency**-তে সিদ্ধান্তমূলক জয়, কিন্তু **thesis**-এর মূল **novelty claim** (impairment-aware IABC-v2 correction একটা 0-parameter classical baseline, DFT-SIC-কে হারাবে) **data** দিয়ে সমর্থিত নয়।

- Efficiency**-তে নিঃসন্দেহে সফল। IABR-Net মাত্র **195,024 params** (Teacher 469,393-এর **41.5%**, Student 314,513-এর 62.0%, FNO 334,321-এর 58.3%) আর **97.17 MFLOPs** (Teacher 15.203 GFLOPs-এর **~156x** কম, Student 10.157 GFLOPs-এর **~104.5x** কম, FNO 0.172 GFLOPs-এর **~1.77x** কম) দিয়ে বানানো (E0b, E9) GPU memory মাত্র 66 MB (বাকি সব **~2.6–2.9x** বেশি), weights ফাইল মাত্র 1.01 MB **batch=128**-এ throughput Teacher-এর 36.6x — তবে এই বিশাল অনুপাত শুধু বড় batch-এ সত্যি: batch=32-এ অনুপাত মাত্র

~7.6×, আর batch=8-এ ~3.0× (IABR-Net-এর latency batch-নির্বিণেয়ে প্রায় flat থাকায়, batch যত বাড়ে অনুপাতও তত বাড়ে)।

- **In-distribution accuracy-তে "মাঝারি" — Teacher আর Student-এর কাছাকাছি, কিন্তু DFT-SIC-এর নিচে সবসময়।** E3 frozen bank (L=3, SNR −10..25 dB)-এ mean paper-style Pd: **DFT-SIC 0.7326 > Teacher 0.7103 > Student 0.6956 > IABR (3-seed mean ≈ 0.6907) > FNO 0.6235** (তিন seed-এর paper Pd হলো s0=0.6909, s1=0.6897, s2=0.6916 — তাদের সঠিক গড় **0.690729 ≈ 0.6907**, headline-এ শুধু s0-এর 0.6909 ব্যবহার করলে সেটা "3-seed mean" নয়, একটা seed-এর একার সংখ্যা।) **Strict Pd-তে** (dropped sample-কে miss ধরলে, যেটা IABR-এর কখনো sample drop না-করার সুবিধা তুলে ধরে) IABR (0.6907) আসলে **Teacher-কে হারায়** (0.6727) এবং Student-কেও (0.6469), তবে DFT-SIC-এর (0.7326) নিচেই থাকে। 15 dB-এ IABR_s0 0.8662 (paper), Teacher 0.8994, DFT-SIC 0.9042 — clean condition-এই IABR প্রায় 3.3–3.8 pp পিছিয়ে।
- যে দাবিটা ব্যর্থ হয়েছে: **"IABC-v2 impairment-aware correction DFT-SIC-কে হারানোর মূল অস্ত্র।"** E4 (phase ≤5°), E5 (gain 0.5–2 dB), E6 (phase 10–15° OOD) — এই তিনটার প্রায় সব condition-এ IABR বনাম Abl1_no_IABC (IABC ছাড়া) পার্থক্য statistically noise-এর মধ্যে (paired bootstrap CI শূন্য বাদ দেয় না)। শুধু একটা **condition-এ** (SNR 15 dB, gain error 4 dB OOD) IABC-এর প্রকৃত, পুনরাবৃত্ত (তিনটা IABC variant-এ) সুবিধা দেখা গেছে — IABR (0.8033) Abl1-এর (0.7790) চেয়ে +2.43 pp এবং Teacher-এর (0.7787) চেয়ে +2.46 pp এগিয়ে। কিন্তু এই একই condition-এ IABR **Student-কে (0.7611) +4.22 pp** ব্যবধানে হারায় — অর্থাৎ IABC-এর লাভ Teacher/Abl1-এর বিরুদ্ধে ~+2.4 pp হলেও Student-এর বিরুদ্ধে অনেক বড়, তাই এই তিনটা তুলনার জন্য একটাই সংখ্যা (" +2.4 থেকে +2.9 pp") ব্যবহার করা ভুল। আর সেখানেও **0-parameter DFT-SIC (0.8387)** IABR-এর (0.8033) চেয়ে এগিয়ে থাকে। প্রতিটা impairment condition-এ (E4/E5/E6, দুটো SNR, সব level) DFT-SIC IABR-কে হারায়।
- যেখানে সবচেয়ে বড় **architectural** দুর্বলতা ধরা পড়েছে: **angular resolution** E8-এ দুটো path 10° কাছাকাছি হলে IABR ধসে পড়ে (0.6145, Teacher 0.9322, DFT-SIC 0.9765) — FNO-এর স্তরে নেমে যায়। কারণ (Abl-2 দিয়ে প্রমাণিত): coarse heatmap মাত্র 16×16, আর 3×3 NMS দুটো কাছের path-কে একই cell-এ merge করে ফেলে। Coarse decode একা Pd মাত্র 0.1396 দেয় — প্রায় পুরো **accuracy** আসে **learned crop-refinement head** থেকে (0.1396 → 0.6909, +55.1 pp)
- **SNR extrapolation-এ** ব্যর্থতা: training range (−15..24 dB)-এর বাইরে, high SNR (30, 35 dB)-এ IABR-এর Pd কমে যায় (0.8554 → 0.8411), যেখানে Teacher বাড়তে থাকে (0.9390 → 0.9465)। High-SNR-এ IABR-এর plateau (~0.87) মূলত দুটো কারণে: কাছাকাছি path merge (SNR≥15-এ wrong-peak path-এর 82% অন্য একটা true path-এর 1.5 cell-এর মধ্যে) আর end-fire sub-cell precision (25 dB-এ miss-এর 85% end-fire-এ)।
- **Training pipeline** নিজে সম্পূর্ণ সুস্থ ও **reproducible**: 3 seed একই জায়গায় converge করে (E3 std মাত্র 0.0010, 95% CI ±0.0024), কোনো divergence নেই।

এক লাইনে: IABR-Net একটা **parameter/FLOP-efficient, robust-to-drop** (কখনো **sample drop** করে না), **moderate-accuracy** architecture — কিন্তু "impairment-aware" নামের মূল novelty claim প্রায় সব robustness test-এ অপ্রমাণিত থেকে গেছে, এবং এর angular resolution ও high-SNR extrapolation-এর সীমাবদ্ধতা এর accuracy-কে DFT-SIC-এর মতো একটা 0-parameter classical method-এর নিচে রেখে দিয়েছে।

Parameter/FLOP headline table

Model	Params	Teacher-এর %	GFLOPs	Teacher-এর তুলনায়	GPU mem (batch32)	Weights file
Teacher	469,393	—	15.203	—	185.85 MB	2.80 MB
Student (r=8)	314,513	67.0%	10.157	1.5× কম	169.84 MB	2.33 MB
FNO	334,321	71.2%	0.172	88.4× কম	187.67 MB	1.40 MB
DFT-SIC	0	—	measure করা হয়নি (CPU)	—	—	—
IABR-Net	195,024	41.5%	0.097	~156× কম	65.74 MB	1.01 MB

২. প্রতিটা experiment ধাপে ধাপে

২.০ Sanity ও Verification chain — E0a, BANKS_build, E0b, V0, V1

এই পাঁচটা gate পুরো run-এর "ভিত্তি"। এরা pass না করলে বাকি কোনো সংখ্যা বিশ্বাসযোগ্য হতো না।

Test	কী verify করে	মূল সংখ্যা	Verdict
E0a (Phase-0 unit tests)	Physics: unitary codebook, simulator == original generator, gain/phase injection, 16↔64 conversion, angle↔cell mapping	11/11 check pass, error ~1e-15 বা 0.0	✓ Success
BANKS_build	56টা fixed robustness bank আছে ও hash অক্ষত	56 bank, sha256 সব মিলেছে (নিজস্ব যাচাই: 0 mismatch)	✓ Success (এই GPU-তে regenerate হয়নি, build_min ≈ 0)
E0b (model instantiation)	IABR-Net-এর আসল params/FLOPs	195,024 params, 97,169,941 FLOPs	✓ Success — estimate (193,104 / 95.3M)-এর 1–2% কাছে, পার্থক্য BatchNorm bookkeeping দিয়ে ব্যাখ্যাযোগ্য
V0 (Teacher reproduces registry)	Weights + evaluator + frozen bank ঠিক আছে কিনা	Teacher mean Pd 0.7102636, registry 0.7103496, diff –8.6e-5	✓ Success — tolerance (2e-3)-এর 23 গুণ ভেতরে, কিন্তু আর "bit-exact" (13+ sig fig) নয়
V1 (generator fidelity)	নতুন vectorized simulator বনাম frozen bank distribution	সব SNR-এ diff < 3σ (0.42σ, 0.32σ, 0.11σ)	✓ Success — coverage সীমিত (শুধু L=3, clean)

Theory/Code সংক্ষেপে: E0a checks করে (ক) w_{ideal}/f_{ideal} unitary কিনা, (খ) vectorized `simulate()` original `DG.generate_channel_v2`-এর সাথে মেলে কিনা, (গ) gain/phase injection সঠিক range-এ আছে কিনা, (ঘ) inverse codebook impairment-কে antenna-domain-এ diagonal matrix হিসেবে ফেরত আনে কিনা (IABC-v2-এর গাণিতিক ভিত্তি — error 7.03e-15), (ঙ) 16×16↔64×64 conversion bit-exact কিনা। V0 frozen 8000-sample bank-এ Teacher চলিয়ে registry-র মান reproduce করে (evaluator/weights/data সব ঠিক প্রমাণ করে)। V1 নতুন generator দিয়ে বানানো clean L=3 bank-এ Teacher-এর Pd frozen bank-এর সমান কিনা (Bernoulli SE-ভিত্তিক 3σ test) দেখে।

কেন গুরুত্বপূর্ণ: এই পাঁচটা gate pass করায়, পরের সব experiment-এ (E3–E11, Abl-) IABR-Net যেখানে পিছিয়ে (E3 mean Pd, high-SNR plateau, E8-এর 10° collapse) বা এগিয়ে (strict Pd, FLOPs), সেই পার্থক্য সিমুলেটর/evaluator/data bug থেকে নয় — model-এর নিজের*।

দুর্বলতা: (১) V0 এবার bit-exact নয় (আগে "13+ sig fig exact" claim ছিল, এখন –8.6e-5 diff) — thesis-এ "reproduces to within 8.6e-5" লিখতে হবে, "bit-exact" নয়। (২) V1-এর coverage সরু (শুধু L=3, clean, ৩টা SNR) (৩) BANKS এই GPU machine-এ regenerate হয়নি, শুধু hash-check হয়েছে। (৪) E0b-এর FLOP breakdown-এ Conv2D ছাড়া বাকি 1.83M FLOP কোন op থেকে এসেছে তা স্পষ্ট নয় (total সংখ্যা ঠিক)।

২.১ Training ও In-distribution headline — TRAIN_s0/s1/s2, E3, E11, SNR_tails

কী test করা হয়েছে: IABR-Net তিনটা seed (0,1,2) দিয়ে পুরো 20,000-step synthetic on-the-fly training; frozen 8000-sample bank (L=3, SNR –10..25 dB)-এ headline comparison; multi-seed variance (E11); training range-এর বাইরে (SNR –25,–20,30,35 dB) extrapolation

Theory: Loss = 1·heat + 1·off + 0.5·pair + 0.1·snr IABR-Net-এর বাজি হলো 16×16 native beamspace grid +

sub-cell offset regression, যা Teacher-এর 256×256 grid-এর তুলনায় FLOPs অনেক কমায়। Hypothesis ছিল (FINAL_RESEARCH_REPORT §27): "IABR-Net-এর PD/RMSE matched SNR-এ DFT-SIC আর Teacher-এর মাঝখানে পড়বে।"

Code সংক্ষেপে: Adam optimizer, cosine LR decay, per-sample $L \sim U\{1..9\}$, $SNR \sim U\{-15..24\}$ dB, per-sample impairment (phase $\delta \sim U(0,5^\circ)$, gain $\gamma \sim U(0,2$ dB)) E3-এ প্রতিটা model frozen bank-এর 16×16 downsample-এ চালানো হয়েছে; IABR-এর `predict_iabr`-এ heatmap sigmoid → `local_maxima` (K=10) → top-L cell → crop-refine offset → angle

Result — training:

seed	final loss	heat	off	pair	snr
s0	0.41664	0.39241	0.02086	0.00616	0.00288
s1	0.41244	0.38859	0.02041	0.00613	0.00376
s2	0.41293	0.38903	0.02052	0.00615	0.00297

তিনটা seed একই জায়গায় (~0.41–0.42) converge করে। s2-তে step 2000→2200-এ একটা resume-artifact spike আছে (loss 0.4464→0.5841, কারণ দ্বিতীয় session-এ checkpoint resume-এর সময় optimizer state ঠিকমতো restore হয়নি বলে মনে হয়) — কিন্তু final metric-এ ক্ষতি হয়নি (s2-ই আসলে সেরা seed, E3 Pd 0.6916) Heat loss মোট loss-এর ~94%, আর 10k step পরে প্রায় flat — architecture/representation-এর সীমা, আরও step দিলে লাভ হবে না।

Result — E3 headline (paper-style, mean over SNR):

model	mean Pd (paper)	mean Pd (strict)	mean Pd (source)
DFT-SIC	0.7326	0.7326	0.6321
Teacher	0.7103	0.6727	0.5775
Student	0.6956	0.6469	0.5458
IABR (3-seed mean)	≈0.6907 (s0 0.6909, s1 0.6897, s2 0.6916)	≈0.6907	≈0.5823
FNO	0.6235	0.6018	0.4575

15 dB-এ: IABR_s0 0.8662, Teacher 0.8994, DFT-SIC 0.9042 High-SNR plateau: IABR 20→25 dB-এ প্রায় flat (0.8733→0.8745), Teacher 0.9251→0.9376 **[derived, cache re-scoring, report 02]** SNR≥15-এ IABR-এর "পুরো path ভুল" ঘটনার 82% এমন path যা অন্য true path-এর 1.5 coarse cell-এর মধ্যে (coarse-grid merge) — Teacher/DFT-SIC-এর এই হার মাত্র 40–42%। 25 dB-এ IABR-এর miss-এর 85% end-fire-এ (end-fire miss rate 0.324 বনাম Teacher 0.162)

Result — E11 (multi-seed variance):

condition	mean	std	values
E3_frozen	0.6907	0.0010	[0.6909, 0.6897, 0.6916]
phase_d5_snr15	0.8501	0.0010	[0.851, 0.8503, 0.849]
gain_g2_snr15	0.8489	0.0025	[0.8463, 0.8513, 0.849]

খুব stable — 95% CI ±0.0024 (E3) শুধু 25 dB-এ per-seed spread বেশি (std 0.0137, বাকি SNR-এ ~0.001–0.003) — training-range-এর কিনারায় model-এর আচরণ অস্থির হওয়ার একটা সংকেত।

Result — SNR_tails (extrapolation, single seed s0):

model	-25 dB	-20 dB	30 dB	35 dB
Teacher	0.0184	0.0257	0.9390	0.9465 (বাড়ছে)
DFT-SIC	0.0213	0.0303	0.9240	0.9370
IABR_s0	0.0190	0.0273	0.8554	0.8411 (কমছে)

Low tail-এ সবাই chance floor-এ (inconclusive) High tail-এ IABR-এর একমাত্র স্পষ্ট দুর্বলতা: SNR বাড়লে performance কমছে, Teacher একই training range পেয়েও বাড়তে থাকে। **Abl3_no_SE**-কে এই **tail bank**-এ চালানো হয়নি — এটা একটা **missing experiment** (mother synthesis নিজেই এটা চিহ্নিত করেছে, ৩ নম্বর research fix হিসেবে §৫-এ প্রস্তাবিত)।




Figure ব্যাখ্যা: তিনটা panel (Pd paper-style, Pd strict, RMSE), সব 11টা model, SNR -10 থেকে 25 dB Panel 1-এ নিম্ন SNR-এ লাল DFT-SIC সবার উপরে, উচ্চ SNR-এ নীল Teacher তাকে ছাড়িয়ে যায়; IABR-এর তিনটা seed + E1 + Abl1 + Abl3 একটা গুচ্ছ হয়ে ~0.87-এ flat হয়ে যায়। Panel 2 (strict)-এ ছবি বদলে যায় — low-mid SNR-এ IABR গুচ্ছ Teacher/Student-এর উপরে (drop policy-র প্রভাব)। **Figure**-এর একটা **bug**: matplotlib-এর 10-রঙ cycle ঘুরে আসায় Teacher আর Abl3_no_SE দুটোই একই নীল রঙে আঁকা হয়েছে — legend দেখে আলাদা করা যায় না, thesis-এ ব্যবহারের আগে ঠিক করতে হবে (দুই independent analyst — report 01 ও 02 — এটা আলাদাভাবে ধরেছে)।

Verdict: Training — ✓ Success (stable, reproducible) E3 — **Mixed** (low-SNR-এ ও strict metric-এ ভালো, কিন্তু DFT-SIC-কে সব SNR-এ হারায়, high-SNR plateau আছে)। E11 — ✓ Success (ordering robust) SNR_tails — **Failure** (high-tail extrapolation ব্যর্থ)।

২.২ Hardware Impairment Robustness — E4 (phase), E5 (gain), E6 (OOD phase)

কী **test** করা হয়েছে: প্রতি antenna-য় random phase error (E4: $\delta \in \{0, 1, 2, 5\}^\circ$, E6 OOD: $\delta \in \{10, 15\}^\circ$) বা gain error (E5: $\gamma \in \{0, 0.5, 1, 2, 4\text{dB}\}$, 4dB = OOD), SNR {0, 15} dB, L=3, 500 sample প্রতি condition Model: Teacher, Student, FNO, DFT-SIC, IABR_s0, E1_capacity_control (IABC আছে, pair loss=0), Abl1_no_IABC (IABC নেই)।

Theory — impairment আসলে কতটা "জোরালো" [**MY ANALYSIS, report 03**]: Distortion-to-signal ratio (DSR) হিসাব করে দেখা যায়:

condition	DSR (dB)	SNR 15-তে noise (-15dB)-এর তুলনায়
phase 5° (training max)	-22.9	নগণ্য (noise-এর ~8dB নিচে)
phase 15° (OOD)	-13.4	noise-এর চেয়ে বেশি
gain 2 dB (training max)	-14.3	প্রায় সমান
gain 4 dB (OOD)	-7.7	noise-এর ~7dB বেশি

অর্থাৎ E4-এর পুরো range ($\leq 5^\circ$) physically noise-এর নিচে ডুবে থাকে — IABC-কে প্রমাণ করার সুযোগ প্রায় নেই। একমাত্র

"active" condition হলো SNR 15-এ gain 4dB (OOD) আরেকটা গুরুত্বপূর্ণ **finding**: প্রতিটা impairment level আলাদা seed/bank-এর, তাই curve-এ ± 2 pp sampling noise থাকে — প্রমাণ: deterministic, training-হীন DFT-SIC-ও SNR 15, $0^\circ \rightarrow 1^\circ$ -এ -1.8 pp নামে, যদিও physics অনুযায়ী প্রভাব শূন্য হওয়ার কথা।

Result (SNR 15 dB, paper-style Pd):


model	E4: 0°	E4: 5°	E5: 2 dB	E5: 4 dB (OOD)	E6: 10°	E6: 15°
Teacher	0.9127	0.8859	0.8541	0.7787	0.8620	0.8081
DFT-SIC	0.9183	0.9007	0.8860	0.8387	0.8870	0.8427
IABR_s0	0.8700	0.8510	0.8463	0.8033	0.8487	0.8043
E1 (pair=0)	0.8757	0.8527	0.8477	0.8003	0.8490	0.7987
Abl1 (no IABC)	0.8737	0.8607	0.8437	0.7790	0.8447	0.8017

Comparison — IABC-এর প্রকৃত অবদান [MY ANALYSIS, paired bootstrap, report 03]:

তুলনা	E4 (5°)	E5 (2 dB)	E5 (4 dB OOD)	E6 (15°)
IABR – Abl1	−0.97 pp (ns)	+0.27 pp (ns)	+2.43 pp [+1.07, +3.87]	+0.27 pp (ns)
IABR – Teacher (strict, paired)	−0.83 pp (ns)	−0.43 pp (ns)	+2.93 pp [+1.17, +4.60]	+0.43 pp (ns)
IABR – DFT-SIC	−4.1 থেকে −5.2 pp (সব significant, শূন্যের নিচে)	−3.97 pp	−3.53 pp	−3.8 pp

একমাত্র জায়গা যেখানে **IABC**-এর লাভ প্রমাণযোগ্য: SNR 15, gain 4 dB (OOD) তিনটা আলাদা IABC-variant (IABR_s0, E1, Abl3_no_SE) সবাই Abl1-এর চেয়ে +2.1 থেকে +2.6 pp এগিয়ে, CI শূন্য বাদ দেয়। কিন্তু এই একই condition-এ IABR **Student**-কে **(0.7611) +4.22 pp** ব্যবধানে হারায় — যা Teacher/Abl1-এর বিরুদ্ধে দেখা +2.4–2.6 pp পরিসরের বাইরে, তাই "Teacher/Student/Abl1-কে +2.4 থেকে +2.9 pp ব্যবধানে হারায়" জাতীয় একক সংখ্যা ভুল — প্রতিটা baseline-এর বিরুদ্ধে margin আলাদা। বাকি সব condition-এ (E4-এর সব level, E5-এর 0–2dB, E6-এর সব level) IABR বনাম Abl1 পার্থক্য noise-এর ভেতরে — IABC-v2 কার্যত কোনো প্রমাণযোগ্য লাভ দেয় না।

গভীর কারণ [report 03 §4]: Training log-এর pair metric দেখায় IABC distortion-এর মাত্র ~24% কমাতে পেরেছে (Abl1-এর raw 0.00815 → IABR-এর 0.00616)। E1 (pair supervision ছাড়া) IABC এমন একটা transform শিখেছে যা clean থেকে ৭.৭ গুণ দূরে (0.0625), তবুও Pd প্রায় সমান — মানে detection performance "clean-এর দিকে correction"-এর উপর নির্ভর করে না। IABC সম্ভবত একটা global re-weighting শিখেছে, সত্যিকারের impairment corrector নয় (hypothesis, সরাসরি inspect করা হয়নি)।







Figure ব্যাখ্যা (E4): SNR 0-তে (উপরের ছবি) সব line-ই phase বাড়ার সাথে সামান্য উপরে উঠছে — এটা sampling artifact, impairment-এর real effect নয় (§0.5)। SNR 15-এ (নিচের ছবি) IABR/E1/Abl1 একটা জট পাকিয়ে আছে, কোনো দৃশ্যমান পার্থক্য নেই; পুরো IABR-family Teacher আর DFT-SIC-এর ~4–5pp নিচে, আর এই ফাঁক impairment বাড়ার সাথে বদলায় না — এটা impairment-robustness-এর সমস্যা নয়, **clean-condition accuracy gap**






Figure ব্যাখ্যা (**E5**, সবচেয়ে তথ্যবহুল **figure**): SNR 15 panel-এ 0–1dB-এ সব line প্রায় সমান্তরাল, কিন্তু 2dB থেকে **Teacher** আর **Student** খাড়া ভাবে নামতে থাকে, আর 4dB-এ Teacher (0.7787) IABR/E1 (~0.80)-এর নিচে চলে যায় — একটা crossover DFT-SIC সবচেয়ে ধীরে নামে, সবসময় সবার উপরে। এটাই পুরো experiment-group-এর একমাত্র জায়গা যেখানে IABC-যুক্ত ও IABC-হাড়া model দৃশ্যমানভাবে আলাদা হয়।

E6-এর কোনো **figure** নেই (e6() plot_sweep() call করে না — code omission, file হারিয়ে যায়নি)।

Verdict: E4 — Mixed/Inconclusive (IABC claim fail to demonstrate) E5 — **Partial success** (একমাত্র 4dB OOD-তে IABC-এর প্রমাণযোগ্য লাভ, কিন্তু DFT-SIC-এর নিচেই)। E6 — Failure for IABC claim, তবে কোনো catastrophic break নেই (graceful degradation)

২.৩ Scene Difficulty — E7 (path count), E8 (angular separation), E10 (nuisance path)

এই তিনটা test-এ কোনো **hardware impairment** নেই (phase=0, gain=0) — তাই IABC-v2-এর এখানে কিছু করার সুযোগ নেই। এই test-গুলো আসলে IABR-এর trunk + 16×16 coarse heatmap + 3×3 NMS decoder + crop-refinement head পরীক্ষা করে।

E7 — Path count sweep (L = 1..8, 10): SNR {0,15}, প্রতি L-এ 500 sample Total power স্থির থাকায় ($\alpha \sim \text{CN}(0, 1/L)$) L বাড়লে প্রতিটা path দুর্বল হয়, আর beamspace-এ path-গুলো ঘন হয়।

SNR 15 paper-style	L=1	L=3	L=5	L=8	L=10
Teacher	0.9430	0.9127	0.8634	0.7867	0.7494
DFT-SIC	0.9450	0.9183	0.8626	0.7951	0.7549
IABR_s0	0.9280	0.8700	0.7988	0.7113	0.6694

paper-style-এ Teacher-এর তুলনায় ফাঁক L1-এ −1.5pp থেকে L10-এ −8.0pp পর্যন্ত ধারাবাহিকভাবে বাড়ে। কিন্তু **strict metric**-এ চিত্র উল্টে যায়: L10 SNR15-এ IABR 0.6694 বনাম Teacher 0.5426 (Teacher 138/500 sample drop করে, IABR কখনো করে না)। L10 SNR0-এ IABR strict 0.3839 বনাম Teacher 0.0676 (Teacher 425/500 drop করে)।

DFT-SIC strict metric-এও প্রতিটা **L**-এ সবার উপরে। OOD ধাপ (L8→L10)-এ IABR-এর কোনো "cliff" নেই — ঢাল DFT-SIC-এর মতোই মসৃণ, তাই এই পতন physics-driven, OOD generalization failure নয়।

E8 — Angular separation sweep (30°→1°, L=2, SNR 15): Training-এ minimum Euclidean separation ছিল 30° — তাই $s \leq 20^\circ$ সব learned model-এর জন্যই কার্যত OOD


separation	Teacher	DFT-SIC	IABR_s0
30°	0.9888	0.9950	0.9935
20°	0.9879	0.9950	0.9760
10°	0.9322	0.9765	0.6145
5°	0.6811	0.5705	0.2880

10° separation-এ IABR ধসে পড়ে (0.6145, Teacher-এর তুলনায় −0.3177, DFT-SIC-এর তুলনায় −0.3620) — FNO-এর (0.6200) স্তরে নেমে যায়। $p_{50}=0.4515^\circ$ কিন্তু $p_{95}=83.31^\circ$ — bimodal: প্রথম path প্রায় নিখুঁত, দ্বিতীয়টা প্রায়ই সম্পূর্ণ ভুল জায়গায় (noise-এর local max) কারণ: 10°-এ দুটো path-এর দূরত্ব u-domain-এ মাত্র ~0.9–1.4 cell, যা 3×3 local-max filter-এর চোখে একটাই peak (3° থেকে 1°-এর মধ্যে Pd আবার বাড়়া দেখা যায় — এটা resolution-এর উন্নতি নয়, 1° threshold-এর একটা metric artefact, design doc-এ আগে থেকেই "diagnostic-only" বলে চিহ্নিত।)

E10 — Nuisance path stress test (3 principal + 1 interferer, power −20/−10/0 dB, 200 scene):

SNR 15, principal Pd	−20 dB	−10 dB	0 dB
Teacher	0.9044	0.8998	0.8795
DFT-SIC	0.8892	0.8700	0.8817
IABR_s0	0.8433	0.8283	0.8150

IABR-এর principal Pd nuisance power বাড়়ার সাথে একটানা নামে (dolation ≤ 0.0283), Teacher/DFT-SIC-এর তুলনায় SNR 15-এ 4–7pp পিছিয়ে। **[FILE, JSON]** IABR-এর principal p_{95} (SNR 15): −20 dB-এ 23.55°, −10 dB-এ 24.49°, 0 dB-এ 52.68° — শক্তিশালী nuisance-এ gross error বেড়ে যায়। (এই সংখ্যাগুলো `E10_nuisance_path.json/tables/E10.md`-এ সরাসরি `pd_principal/pd_nuisance column`-এ আছে, তবে **p95 field** রাখা হয়নি — এই **p95** বিশ্লেষণটা **report 04**-এর নিজস্ব **cached-prediction re-scoring script** থেকে এসেছে, তাই **raw file** দিয়ে সরাসরি **cross-verify** করা যায়নি — **verifier** একে **"UNVERIFIABLE"** চিহ্নিত করেছে, বিস্তারিত §৬-এ।) কম SNR-এ strict metric-এ IABR Teacher-এর চেয়ে অনেক ভালো (−20dB-এ 0.6425 বনাম 0.3717, Teacher 81/200 scene drop করে)। **PROJECT_STATUS**-এর আগের **"Student beats Teacher under nuisance"** ফল এই নতুন **bank**-এ **reproduce** হয়নি ($\Delta = -0.0316$, উল্টো দিকে) — সম্ভবত সেটা sampling noise ছিল।






Figure ব্যাখ্যা: SNR 15 (নিচের ছবি)-তে Teacher ও DFT-SIC প্রায় এক line হয়ে উপরে থাকে (0.94→0.75); IABR-family খাড়া ঢালে নেমে L10-এ ~0.67-এ পৌঁছায় — দুই গোষ্ঠীর মধ্যে ক্রমশ চওড়া হওয়া একটা "wedge" তৈরি হয়। এটা high-SNR-এ noise আর সমস্যা না হওয়ায় যা বাকি থাকে তা হলো resolution আর sub-cell precision




Figure ব্যাখ্যা (y-axis এখানে pd_source , pd_paper নয়): IABR-family (বেগুনি/বাদামি/গোলাপি) 20° পর্যন্ত DFT-SIC/Teacher-এর কাছাকাছি (~0.97–0.99), কিন্তু 10°-এ হঠাৎ ~0.59-এ ধস — Teacher/Student-এর অনেক নিচে। এটাই এই পুরো test-suite-এর সবচেয়ে স্পষ্ট, একক architectural failure

E10-এর কোনো figure নেই (শুধু table)

Verdict: E7 — Mixed (strict/কম-SNR-এ ভালো, paper-style high-SNR-এ ফাঁক বাড়ে) । E8 — Mixed, কিন্তু 10°-এ স্পষ্ট **Failure** E10 — Mixed (robust কিন্তু কম accurate)

২.৪ Ablations ও Controls — E1, E2, Abl1, Abl3, Abl-2, Abl-6

Controls টেবিল (E3_frozen mean Pd + robustness condition, paper-style):

model	params	E3_frozen	phase_d5_snr15	gain_g2_snr15	gain_g4_snr15
IABR_s0 (main)	195,024	0.6909	0.8510	0.8463	0.8033
E1_capacity_control (pair=0)	195,024	0.6887	0.8527	0.8477	0.8003
E2_dense_frontend	457,430	0.5704	0.7473	0.7467	0.6527
Abl1_no_IABC (front=none)	194,774	0.6871	0.8607	0.8437	0.7790
Abl3_no_SE	192,093	0.6854	0.8537	0.8437	0.8047

E1_capacity_control — মূল architecture হুবহু একই, শুধু $\lambda_3(\text{pair})=0$ সব condition-এ IABR_s0-এর $\leq 0.3\text{pp}$ -এর মধ্যে থাকে $\rightarrow$ **L_pair loss** কার্যত অকার্যকর প্রমাণিত (Abl-6 sweep-এও একই সিদ্ধান্ত, নিচে দেখুন) । **methodology caveat:** design doc-এ E1-কে "same-capacity, no-adaptivity" module বলার কথা ছিল, বাস্তবায়িত E1 আসলে IABC আছে এমন architecture, শুধু pair loss=0 — এই ভূমিকাটা বরং **Abl1** পালন করে (params প্রায় identical, 194,774 বনাম 195,024, IABC সম্পূর্ণ নেই) ।

E2_dense_frontend — IABC-v2-এর বদলে একটা সাধারণ Dense (512→512) front-end, 457,430 params (~2.34× বেশি) । প্রতিটা condition-এ E1-এর চেয়ে 10–15pp খারাপ (gain_g4-এ -14.8pp), যদিও params অনেক বেশি — এমনকি Abl1 (front='none', কোনো correction-ই নেই)-এর চেয়েও খারাপ । **Physics-informed inductive bias > raw capacity** — এই সিদ্ধান্তের সবচেয়ে জোরালো প্রমাণ ।

Abl1_no_IABC — IABC-এর "pure" ablation (params প্রায় identical to main) E1-এর তুলনায়: E3_frozen প্রায় সমান, phase_d5-এ Abl1 বরং একটু ভালো (+0.80pp), কিন্তু **gain_g4 (OOD)-এ IABR-family** স্পষ্টভাবে এগিয়ে (E1 0.8003 বনাম Abl1 0.7790, +2.13pp) এটাই IABC-এর একমাত্র condition-specific, প্রমাণযোগ্য সুবিধা ।

Abl3_no_SE — SE attention সম্পূর্ণ সরিয়ে দিলে (192,093 params, 2,931 কম) সব condition-এ IABR_s0-এর $\leq 0.6\text{pp}$ -এর মধ্যে, দিক মিশ্র (দুই condition-এ SE ছাড়া বরং একটু ভালো) । **SE attention** কার্যত অকার্যকর ।

Abl-2 — Decode ablation (headline finding of this group):

decode mode	pd_paper	p50	p95_broadside	p95_endfire
coarse (16×16 grid center শুধু)	0.1396	3.6746°	71.29°	173.80°
parabolic interpolation	0.1786	2.7907°	57.31°	170.77°
learned refine (আসল IABR)	0.6909	0.3711°	43.37°	164.29°

Coarse-only decode-এ Pd মাত্র **0.1396** (86% component ভুল)! **Learned crop-refinement head** একলাফে **Pd 0.6909**-এ নিয়ে যায় — **coarse**-এর তুলনায় **+55.1 pp** IABR-Net-এর প্রায় পুরো accuracy এই refinement head থেকে আসে, শুধুমাত্র 41.5% params দিয়ে Teacher-এর (0.7158, pooled) 96.5% আর DFT-SIC-এর (0.7326) 94.3% accuracy পৌঁছায় । তবে **end-fire tail** এখনও অমীমাংসিত: p95_endfire সব model-এই বিশাল (161°–174°, physics-driven, model-independent Jacobian singularity), আর learned-refine সামান্য সবচেয়ে ভালো (164.29°) হলেও কোনো বড় উন্নতি নেই ।

Abl-6 — Loss-weight sweep ($\lambda_3 \in \{0,0.1,0.5,1.0\} \times \lambda_4 \in \{0,0.1,0.3\}$, 12 run, 5000 step single-seed):

E3_subset_pd রেঞ্জ 0.6555–0.6601 (0.46pp spread), phase5_pd 0.8150–0.8303 (1.53pp), gain2_pd 0.8040–0.8180 (1.40pp) Main model-এর নিজের weight ($\lambda_3=0.5$, $\lambda_4=0.1$) কোনো metric-এই সেরা না। এই **architecture loss-weight choice**-এর প্রতি খুবই **robust** — কিন্তু এটাও নিশ্চিত করে যে **main**-এর জন্য বেছে নেওয়া **weight**-এর কোনো বিশেষ যৌক্তিকতা এই **sweep** থেকে পাওয়া যায় না।

training_loss.png-এর ডান panel এই 12-run sweep দেখায় — সব curve প্রায় identical trajectory-তে ~0.42–0.43-এ converge করে, একে অপরের থেকে আলাদা করা প্রায় অসম্ভব — visually এই robustness নিশ্চিত করে। বাম panel-এ E2_dense_frontend আলাদাভাবে (উঁচুতে, ধীরে) নামে, আর IABR_s2-তে resume-artifact spike দেখা যায়।

Verdict: E1 — Neutral (pair loss কার্যত অকার্যকর)। E2 — **Strong confirmatory failure** (দিয়ে বোঝা যায় architecture-ই কারণ, capacity নয়)। Abl1 — Neutral bulk, শুধু gain4-এ +2.13pp Abl3 — Failure (SE অকার্যকর)। Abl-2 — ✓ **Headline success** (refinement head-ই মূল ইঞ্জিন)। Abl-6 — ✓ Robust, কিন্তু tuning-এর ন্যায্যতা দুর্বল।

২.৫ Efficiency — E9 (params/FLOPs/latency/memory)

Result — মূল সারণি:

model	params	GFLOPs	weights_MB	gpu_peak_MB	nn_ms (b=1)	e2e_ms	mean_pd
Teacher	469,393	15.203	2.80	186	7.850	9.48	0.7103
Student	314,513	10.157	2.33	170	7.092	8.76	0.6956
FNO	334,321	0.172	1.40	188	1.251	2.64	0.6235
IABR-Net	195,024	0.097	1.01	66	3.650	4.25	0.6909
DFT-SIC	0	—	—	—	—	8.03	0.7326

Batch-sweep latency (throughput/s):

model	b=1	b=8	b=32	b=128 (throughput/s)
Teacher	7.85 ms	10.35 ms	28.68 ms	141.95 ms (901.75/s)
Student	7.09 ms	10.68 ms	24.41 ms	116.38 ms (1099.82/s)
FNO	1.25 ms	1.41 ms	4.74 ms	24.34 ms (5259.62/s)
IABR-Net	3.65 ms	3.50 ms	3.77 ms	3.88 ms (32992.61/s)

IABR-Net-এর latency batch 1→128 জুড়ে প্রায় **flat** (3.65→3.50→3.77→3.88 ms), মানে GPU compute-saturate হচ্ছে না — kernel-launch/overhead-bound Teacher/Student/FNO-এর latency batch-এর সাথে প্রায় linear বাড়ে। ফলে batch-128-এ IABR-Net-এর throughput Teacher-এর **36.6×**, Student-এর 30.0×, FNO-এর 6.3× — কিন্তু এই বিশাল multiplier ছোট batch-এ অনেক কমে যায়: **batch=32-এ Teacher-এর তুলনায় মাত্র ~7.6×** (**8480.0 বনাম 1115.9 sample/s**), **batch=8-এ মাত্র ~3.0×** (**2287.7 বনাম 773.3**)। তাই "batch≥32-এ 36.6×" জাতীয় সাধারণীকরণ ভুল — এই ratio শুধু batch=128-এ সত্যি।

একটা **genuinely negative finding**: batch=1 real-time inference-এ IABR-Net সবচেয়ে দ্রুত না — **FNO NN-only**-তে **~2.92×** এবং **end-to-end**-এ **~1.61×** দ্রুত, যদিও FNO-এর FLOPs (0.172G) IABR-এর (0.097G) চেয়ে বেশি এবং accuracy অনেক খারাপ (Pd 0.6235 বনাম 0.6909)। কারণ: IABR-এর pipeline-এ per-element IABC correction, top-K gather, crop-based refine head — এই ছোট, sequential, gather/index-heavy op batch=1-এ kernel-launch overhead-dominated; FNO বড় কিন্তু fusable conv/FFT op চালায়। "কম FLOPs/params = কম latency" ধারণা সবসময় সত্য নয়।

Decode-cost বিভাজন **[derived]**: IABR-Net-এর NN-e2e gap (≈ 0.60 ms) সব model-এর মধ্যে সবচেয়ে সস্তা (Teacher ≈ 1.63 ms, FNO ≈ 1.39 ms) — 16×16 coarse heatmap-এর peak-search 256×256 blob-detector-এর চেয়ে $\sim 2.3\text{--}2.8\times$ সস্তা।

Accuracy-per-efficiency: Pd per 100K params: IABR-Net 0.3543 (সব NN baseline-এর সেরা)। Pd per GFLOP: IABR-Net $\approx 7.11\text{--}7.12$ (FNO-এর প্রায় দ্বিগুণ; **note**: rounded 0.097 GFLOPs দিয়ে হিসাব করলে 7.123–7.124 আসে, precise 0.09717 দিয়ে 7.11 — সিদ্ধান্ত একই থাকে, শুধু rounding artifact)

Verdict: Mixed, কিন্তু সার্বিকভাবে ইতিবাচক দিকে ঝুঁকে থাকা একটা সফলতা। Params/FLOPs/memory/high-batch-throughput-এ decisively জিতেছে, pre-run estimate প্রায় ছবছ মিলেছে। কিন্তু batch=1 real-time inference-এ FNO দ্রুততর, আর hypothesis "e2e latency may narrow the gap" ভুল প্রমাণিত হয়েছে (gap প্রায় একই থেকে গেছে)। এই group-এর জন্য কোনো figure/visualization তৈরি হয়নি।

৩. Master Comparison Table — সব experiment এক নজরে

#	Experiment	কী test করে	IABR-Net result	Best baseline	Verdict
E0a	Phase-0 unit tests	Physics/simulator সঠিকতা	11/11 pass, error $\sim 1e-15$	—	✓ Success
BANKS_build	56 fixed eval bank	Data integrity	56/56 hash match	—	✓ Success (এই GPU-তে regenerate হয়নি)
E0b	Model instantiation	Real params/ FLOPs	195,024 params, 97.17M FLOPs	Teacher 469,393/15.20G	✓ Success
V0	Teacher registry reproduce	Evaluator/weights/ bank সঠিকতা	Teacher mean Pd 0.71026 (registry 0.71035, diff $-8.6e-5$)	—	✓ Success (আর bit-exact নয়)
V1	নতুন generator fidelity	Simulator distribution match	সব SNR-এ diff $< 3\sigma$	—	✓ Success (coverage সীমিত)
TRAIN_s0/s1/s2	Training convergence	Loss ও seed stability	final loss 0.4124–0.4166	—	✓ Success (s2 resume spike)
E3	In-dist SNR sweep, headline	Paper Pd 3-seed mean 0.6907 , strict 0.6907	DFT-SIC 0.7326, Teacher strict 0.6727	Mixed — strict-এ Teacher-কে হারায়, DFT-SIC-এর কাছে সব metric-এ হারে	
E11	Multi-seed variance	Reproducibility	std 0.0010–0.0025	—	✓ Success
SNR_tails	OOD SNR extrapolation	Generalization	30/35dB: 0.8554→0.8411 (কমছে)	Teacher: 0.9390→0.9465 (বাড়ছে)	✗ Failure (high tail)
E4	Phase error $\leq 5^\circ$	IABC benefit, low impairment	SNR15,5°: 0.8510 (Abl1 0.8607, খারাপ)	Teacher 0.8859, DFT-SIC 0.9007	✗ IABC-এর প্রমাণযোগ্য লাভ নেই

E5	Gain error, incl. OOD 4dB	IABC benefit	SNR15,4dB(OOD): 0.8033 , vs Teacher +2.46pp, vs Abl1 +2.43pp, vs Student +4.22pp	Teacher 0.7787, DFT-SIC 0.8387	△ Partial success — DFT-SIC-এর নিচে
E6	OOD phase 10–15°	Distribution-shift	SNR15,15°: 0.8043 (Abl1 0.8017, ns)	Teacher 0.8081, DFT-SIC 0.8427	✗ IABC claim fail, graceful degradation
E7	Path count L=1..10	Multipath capacity	SNR15 paper L1 0.928→L10 0.6694; strict L10 0.6694 vs Teacher 0.5426	Teacher (paper, high-L), DFT-SIC (strict)	Mixed
E8	Angular separation 30°→1°	Resolution limit	10°-এ ধস: 0.6145	Teacher 0.9322, DFT-SIC 0.9765	✗ Clear failure
E10	Nuisance path	Interference robustness	Principal Pd দোলা ≤0.0283, SNR15@0dB 0.8150	Teacher 0.8795, DFT-SIC 0.8817	Mixed
E1 (pair=0)	পেয়ার-লস দরকার কিনা	সব condition <0.3pp পার্থক্য	—	Neutral — pair loss কার্যত অকার্যকর	
E2 (dense frontend)	Capacity বনাম architecture	E3: 0.5704 (main-এর চেয়ে 12.0pp খারাপ, 2.34× বেশি params)	—	✓ Strong confirmatory failure	
Abl1 (no IABC)	IABC pure ablation	E3: 0.6871 (main 0.6907, Δ −0.0038, ns)	—	Neutral bulk; শুধু gain_g4-এ +2.13pp	
Abl3 (no SE)	SE attention দরকার কিনা	সব condition <0.6pp পার্থক্য	—	✗ Failure — SE কার্যত অকার্যকর	
Abl-2	Decode ablation	Accuracy কোথা থেকে আসে	coarse 0.1396 → learned-refine 0.6909 (+55.1pp)	Teacher 0.7158, DFT-SIC 0.7326 (pooled)	✓ Headline success
Abl-6	Loss-weight sweep	λ3×λ4 sensitivity	Spread 0.46–1.53pp সব 12 combo-তে	—	✓ Robust, tuning ন্যায্যতা দুর্বল
E9	Efficiency	Compute efficiency	195,024 params, 0.097 GFLOPs, 66MB, b128 throughput 32,993/s (Teacher-এর 36.6×, শুধু b128-এ)	Teacher (params/FLOPs), FNO (b=1 latency 2.9× দ্রুত)	Mixed-positive

8. Success / Failure / Improvement

8.১ Success (গুরুত্ব অনুযায়ী)

- Efficiency claim** পুরোপুরি নিশ্চিত ও **measurement-ভিত্তিক (E0b, E9)**: 195,024 params (est. 193,104-এর 1% কাছে), 97,169,941 FLOPs (~156× কম Teacher-এর চেয়ে)। GPU memory 66MB (~35% Teacher-এর)। batch-128 throughput Teacher-এর 36.6× (batch=32-এ ~7.6×, batch=8-এ ~3.0×)।
- Learned crop-refinement head IABR-Net-এর accuracy-র** প্রায় পুরো উৎস (**Abl-2**): coarse-only 0.1396 → learned-refine 0.6909 (+55.1pp), Teacher-এর 96.5% ও DFT-SIC-এর 94.3% অর্জন মাত্র 41.5% params দিয়ে।

3. **Physics-informed architecture > raw capacity**, সরাসরি প্রমাণিত (**E2 vs E1/Abl1**): $2.34\times$ বেশি params দিয়েও dense front-end 10–15pp খারাপ করে।
4. কখনো **sample drop** করে না: সব robustness experiment-এ $n_dropped=0$, তাই strict metric-এ কঠিন scene-এ Teacher/Student-কে বড় ব্যবধানে হারায় (E7 L10 strict: 0.3839 vs 0.0676; E10 SNR0/–20dB: 0.6425 vs 0.3717)
5. **Training সম্পূর্ণ reproducible ও stable**: 3-seed E3 std 0.0010, gain_g2 std 0.0025, কোনো divergence নেই।
6. **Sanity/verification chain সম্পূর্ণ pass**: simulator, evaluator, weights, frozen bank — সব bug-free প্রমাণিত, তাই বাকি সব দুর্বলতা model-এর নিজের, infrastructure-এর নয়।
7. একমাত্র **OOD condition-এ IABC-এর প্রকৃত সুবিধা**: SNR15, gain 4dB — retention 92.3% (সর্বোচ্চ সব model-এ), Teacher/Abl1-কে হারায় (+2.4–2.9pp, তিনটা IABC variant-এ পুনরাবৃত্ত)।

8.২ Failure/Weakness (গুরুত্ব অনুযায়ী)

1. [সবচেয়ে গুরুত্বপূর্ণ] **DFT-SIC (0 params)**-কে কোনো **test-এ** হারাতে পারেনি। E3, E4, E5 (এমনকি IABC-এর সেরা condition-এও), E6, E7 (strict), E8, E10 (SNR15) — সব জায়গায় হারে। Research report-এর central hypothesis "IABC-v2 এই critical 0-param baseline-কে হারাবে" ব্যর্থ।
2. **Angular resolution** — সবচেয়ে বড় **architectural gap** E8: 10° separation-এ 0.6145 (Teacher 0.9322, DFT-SIC 0.9765) কারণ 16×16 grid + 3×3 NMS-এর effective resolution Rayleigh limit-এর দ্বিগুণ খারাপ (Abl-2 root-cause confirm করে)।
3. **SNR extrapolation** ব্যর্থতা। 30dB→35dB-এ P_d 0.8554→0.8411 (কমছে), Teacher 0.9390→0.9465 (বাড়ছে)। Abl3_no_SE-কে tail-এ test করা হয়নি — missing experiment
4. **IABC-v2-এর core claim** বেশিরভাগ ক্ষেত্রে অপ্রমাণিত। E4-এর সব level, E5-এর 0–2dB, E6-এর সব level-এ IABR বনাম Abl1 পার্থক্য noise-এর ভেতরে। IABC distortion-এর মাত্র ~24% সরাতে পারে।
5. **High-SNR plateau ~0.87, coarse-grid merge-এর কারণে**। $SNR\geq 15$ -এ wrong-peak path-এর 82% অন্য true path-এর 1.5 cell-এর মধ্যে (merge failure)
6. **L বাড়লে high-SNR-এ ধারাবাহিক পতন (E7)**: L1 (–1.5pp) থেকে L10 (–8.0pp), Teacher-এর তুলনায়।
7. **End-fire precision** অমীমাংসিত (**Abl-2, V0, E3**): learned-refine-এও $p95_endfire \sim 164^\circ$, physics-level Jacobian singularity
8. **SE attention** কার্যত অকার্যকর (**Abl3**): সব condition-এ $<0.6pp$ পার্থক্য, দিক মিশ্র।
9. **batch=1 real-time inference-এ IABR** সবচেয়ে দ্রুত না (**E9**): FNO NN-only-তে $\sim 2.92\times$, e2e-তে $\sim 1.61\times$ দ্রুত, যদিও accuracy অনেক খারাপ।
10. **E10 nuisance-এ SNR15-তে 4–7pp** পিছিয়ে, শক্তিশালী interferer-এ gross error বাড়ে (নোট: exact magnitude derived cache-analysis থেকে, §৬ দেখুন)।

8.৩ Improvement Ideas (গুরুত্ব অনুযায়ী)

1. **Heatmap resolution** বাড়ানো (সর্বোচ্চ **priority** — **E8/E7/E3/E10** সব দুর্বলতার **common root cause**): oversampled beamspace ($32\times 32/64\times 64$), অথবা trunk 16×16 রেখে pixel-shuffle upsample, অথবা multi-anchor per cell লক্ষ্য: E8-এর 10° -এ $P_d \geq 0.93$
2. **SNR extrapolation** ঠিক করা: training SNR range বাড়ানো, input normalization, SE-SNR coupling কমানো, এবং Abl3_no_SE-কে tail bank-এ চালানো (missing diagnostic)
3. **IABC-কে সত্যিকারের impairment corrector** বানানো: iterative/deep-unfolded calibration, scale/phase-invariant pair loss, training impairment range/strength বাড়ানো।
4. **SIC-style iterative detection** বা **DFT-SIC-এর সাথে hybrid** — DFT-SIC-এর "subtract strongest, re-detect" কৌশল resolution (E8) ও masking (E10) দুই সমস্যাতেই জেতে।

5. **Objectness/confidence head + learned L estimation** — spurious peak কমাতে, "never drops" সুবিধা রেখেও false-positive কমাতে।
6. **$\lambda 3$ (pair loss)** সরিয়ে দেওয়া বিবেচনা করা — দুই independent test (E1, Abl-6) একই সিদ্ধান্তে।
7. **End-fire-aware loss/parameterization** — sin/cos (direction-cosine) offset representation
8. **Statistical rigor** বাড়ানো: সব ablation-এ ≥ 3 seed, robustness bank-এ paired design (একই scene, শুধু impairment বদলানো)।
9. **Reporting fix:** E3/E8 figure-এর color bug ঠিক করা, E6-এর missing figure যোগ করা, "bit-exact" claim সংশোধন, প্রতিটা table-এ paper ও strict Pd পাশাপাশি রাখা।

৫. এখন কী করা উচিত — Research agent-এর ranked next-step plan

RESEARCH agent (09_next_steps_research.md) mother synthesis-এর প্রতিটা top weakness-এর জন্য real web research (WebSearch + WebFetch, প্রতিটা citation-এর URL সরাসরি খোলা হয়েছে) করে literature-backed fix খুঁজেছে। কোনো citation বানানো হয়নি।

দ্রুত মানচিত্র

Weakness	মূল প্রস্তাবিত fix	মূল citation
DFT-SIC-কে কখনো হারায়নি	Resolution বাড়ানো + confidence head + deep-unfolded SIC	Huang+23, Klioui'25, Shmuel+23/24, Schieler+24
10° resolution collapse	Finer heatmap grid	Off-grid DOA framework (Huang+23)
SNR extrapolation ব্যর্থতা	Designed training-SNR distribution	Luan & Thompson, ICC 2023
IABC-v2 core claim প্রায় অপ্রমাণিত	Physics-grounded impairment loss	Mateos-Ramos+24, SDOA-Net (Chen+24)
High-SNR plateau, L বাড়লে খারাপ	(resolution fix + confidence head)	(same as above) + Schieler+24
SE attention অকার্যকর	SE→ECA বা remove	ECA-Net, Wang+ CVPR 2020
End-fire precision অমীমাংসিত	sin/cos direction-cosine parameterization	Biternion Nets, Beyer+ DAGM 2015

Ranking — Impact vs Effort

Rank	Fix	Impact	Effort	কারণ
1	A — Resolution বাড়ানো	সবচেয়ে বেশি (E3/E7/E8-এর common root cause)	মাঝারি	একটাই architecture change, তিনটা independent experiment-এ প্রভাব ফেলবে
2	F — sin/cos end-fire parameterization	মাঝারি (দীর্ঘদিনের unsolved issue)	খুবই কম	শুধু loss/target বদল, দ্রুততম ROI
3	C — Designed SNR training distribution	মাঝারি	খুবই কম	data/training recipe change, নতুন param না
4	E — SE→ECA/remove	কম-মাঝারি	খুবই কম	Abl3 framework already আছে
5	G — Confidence/objectness head	মাঝারি	মাঝারি	নতুন head + loss term
6	D — Physics-grounded IABC loss	মাঝারি (thesis core claim বাঁচানো/খারিজ করা)	মাঝারি	নতুন loss design+tuning দরকার

7	B — Deep-unfolded SIC-style refine	সবচেয়ে বেশি সম্ভাব্য (thesis-এর central hypothesis বাঁচতে পারে)	উচ্চ	নতুন iterative block, বেশি compute/debug সময়
---	---	--	------	---

মূল citation-গুলো (URL সরাসরি WebFetch দিয়ে verify করা)

- **Off-Grid DOA Estimation via Deep Learning Framework** — Huang, Zhang, Tao et al., *Science China Info. Sci.*, 2023. <https://link.springer.com/article/10.1007/s11432-022-3750-5>
- **SubspaceNet: Deep Learning-Aided Subspace Methods for DoA Estimation** — Shmuel, Merkofer, Revach, van Sloun, Shlezinger, arXiv:2306.02271 (2023/2024)
- **Circulant ADMM-Net for Fast High-resolution DoA Estimation** — Klioui, arXiv:2502.19076 (2025)
- **Achieving Robust Generalization for Wireless Channel Estimation Neural Networks by Designed Training Data** — Luan, Thompson, IEEE ICC 2023, arXiv:2302.02302
- **Unsupervised Learning for Gain-Phase Impairment Calibration in ISAC Systems** — Mateos-Ramos, Häger, Keskin, Le Magoarou, Wymeersch, arXiv:2410.04176 (2024)
- **SDOA-Net: An Efficient Deep Learning-Based DOA Estimation Network for Imperfect Array** — Chen, Chen, Liu, Chen, Wang, IEEE TIM, 2024, arXiv:2203.10231
- **Grid-free Harmonic Retrieval and Model Order Selection using Deep CNNs** — Schieler, Semper, Faramarzhangari, Döbereiner, Schneider, Thomä, EuCAP 2024, arXiv:2211.04846
- **ECA-Net: Efficient Channel Attention for Deep CNNs** — Wang, Wu, Zhu, Li, Zuo, Hu, CVPR 2020, arXiv:1910.03151
- **Biternion Nets: Continuous Head Pose Regression from Discrete Training Labels** — Beyer, Hermans, Leibe, DAGM 2015

Thesis-timeline plan

- ধাপ ১ (১–২ সপ্তাহ, কম **effort**, দ্রুত ফলাফল): Fix F (sin/cos end-fire parameterization), Fix C (SNR training distribution + missing Abl3_no_SE tail run), Fix E (SE→ECA variant, Abl3_eca) তিনটাই independent, parallel-এ চালানো সম্ভব, fail করলেও thesis-এর ক্ষতি নেই।
- ধাপ ২ (২–৪ সপ্তাহ, মূল **architecture change**): Fix A (heatmap resolution/pixel-shuffle upsample), Fix G (confidence/objectness head) সাথে বাউন্ডেল করা।
- ধাপ ৩ (২–৩ সপ্তাহ, **thesis narrative**-নির্ধারক, সময় থাকলে): Fix D (physics-grounded IABC loss) — "IABC কি সত্যিই impairment-aware, নাকি শুধু efficiency architecture?" প্রশ্নের চূড়ান্ত উত্তর।
- ধাপ ৪ (**future work/stretch**): Fix B (deep-unfolded SIC-style iterative refinement) — সবচেয়ে বড় সম্ভাবনা DFT-SIC-কে সত্যিই হারানোর, কিন্তু কার্যত একটা নতুন architecture paper-level কাজ; deadline না মিললে "Future Work" section-এ concrete proposal হিসেবে রাখা।

সততা ও সীমাবদ্ধতা: এই research সম্পূর্ণ literature-নির্দেশিত hypothesis — কোনো fix এখানে বাস্তবায়ন/পরীক্ষা করা হয়নি। বেশ কিছু paper শুধু abstract/landing-page থেকে verify করা হয়েছে (full PDF text সবসময় পড়া যায়নি)। Cost estimate সব আনুমানিক।

৬. Caveats ও Verifier Correction Summary

08_verification.md-এ ৩৩টা numeric claim হাতে যাচাই করা হয়েছে raw outputs/results/*.json, outputs/tables/*.md, outputs/RESULTS.md-এর বিপরীতে। ফলাফল: ২৯টা **CORRECT**, ৩টা **WRONG**, ১টা **UNVERIFIABLE** এই ফাইনাল রিপোর্টে চারটাই নিচের মতো সংশোধন/চিহ্নিত করা হয়েছে (আর কোনোটা mother synthesis-এর অসংশোধিত ভাষা

ব্যবহার করছে না):

#	মূল ভুল দাবি (07-এ যেভাবে ছিল)	সংশোধিত/সঠিক মান	এই রিপোর্টে কোথায় ঠিক করা হয়েছে
1	"IABR (0.6909, 3-seed mean)"	প্রকৃত 3-seed mean 0.690729 $\approx$ 0.6907 — 0.6909 শুধু IABR_s0-এর একর মান, "3-seed mean" নয়	§১ Executive Summary, §২.১
2	"batch $\geq$ 32-এ throughput Teacher-এর 36.6x"	36.6x শুধু batch=128 -এ সত্যি। batch=32-এ $\sim 7.6\times$, batch=8-এ $\sim 3.0\times$	§১, §২.৫, §৩, §৪.১
3	Master table E5 row: "Teacher/ Student/Abl1-কে হারায় (+2.4 থেকে +2.9pp)"	vs Teacher +2.46pp, vs Abl1 +2.43pp (এই দুটো range-এ), কিন্তু vs Student +4.22pp (range-এর বাইরে) — একটা combined range ভুল	§২.২, §৩
4	"মাত্র 41.6% params দিয়ে"	41.5% (195,024/469,393), মূল ডকুমেন্টের নিজের §1-এর সাথেই সামঞ্জস্যহীন ছিল	§১, §২.৪

একটা **UNVERIFIABLE claim** চিহ্নিত করা হয়েছে (সংখ্যা রাখা হয়েছে কিন্তু **provenance** স্পষ্ট করে দেওয়া হয়েছে): "E10: nuisance শক্তিশালী হলে principal p95 23.55°→52.68°-এ লাফায় (SNR15)" রাজ E10_nuisance_path.json/
tables/E10.md-এ শুধু pd_principal/pd_principal_strict/pd_nuisance column আছে — কোনো p95 field নেই। এই
সংখ্যাটা report 04-এর নিজস্ব cached-prediction re-scoring script (04_scene_difficulty.md) থেকে এসেছে —
নিজের ভেতরে consistent এবং official Pd-এর সাথে মিলিয়ে যাচাই করা, কিন্তু raw JSON/table থেকে স্বাধীনভাবে cross-
check করা যায়নি। §২.৩-এ এটা explicit note সহ রাখা হয়েছে।

অন্যান্য গুরুত্বপূর্ণ **caveat** (verifier-এর নিশ্চিত করা)

- কোনো **omitted experiment** নেই: status.json-এর ৩৭টা key-এর প্রতিটাই কোনো না কোনো group report (01–06) বা mother synthesis (07)-এ নাম ধরে আলোচিত হয়েছে।
- কোনো **undiscussed figure** নেই: outputs/figures/-এর ৯টা PNG-ই কোনো না কোনো report-এ reference/
discuss করা হয়েছে। E6, E9, E10, Abl-2, Abl-6-এর জন্য কোনো figure file-ই ship হয়নি (notebook design
choice, missing file নয়) — mother synthesis নিজেই এটা সঠিকভাবে flag করেছিল।
- Sample size** ছোট, **robustness experiment**-এ: E4/E5/E6/E7/E8 প্রতি condition-এ মাত্র 500 sample (E10-
এ 200), binomial SE ~ 0.009 – 0.013 বেশিরভাগ ablation single-seed (শুধু main IABR-এর 3 seed আছে,
E11)
- V0** আর **"bit-exact" claim**: এই run-এ diff $-8.6e-5$, আগের "13+ sig fig exact" দাবির বিপরীতে। ব্যাখ্যাযোগ্য
(GPU kernel/oneDNN পার্থক্য) কিন্তু thesis-এ ভাষা সংশোধন দরকার: "reproduces to within $8.6e-5$ ", "bit-exact"
নয়।
- E1_capacity_control** নামের সাথে বাস্তবায়নের গরমিল: design doc-এ "same-capacity, no-adaptivity"
module চাওয়া হয়েছিল, বাস্তবায়িত E1 আসলে main-এর হুবহু architecture (শুধু pair loss=0) Abl1_no_IABC-ই
আসলে এই ভূমিকা পালন করে — thesis-এ স্পষ্ট করে লিখতে হবে।
- PROJECT_STATUS**-এর **"Student beats Teacher under interference" claim E10-এ reproduce** হয়নি
($\Delta -0.0316$, বিপরীত দিকে) — আগের ফল সম্ভবত sampling noise ছিল।
- "IABC কী শিখেছে"** সরাসরি **inspect** করা হয়নি — predicted (δ , $\hat{y}$) বনাম আসল (ϵ , g)-এর correlation কখনো
measure করা হয়নি; "IABC একটা global re-weighting শিখেছে, impairment corrector নয়"-এই ব্যাখ্যা একটা
hypothesis, direct প্রমাণ নয়।
- Research agent (09)**-এর নিজস্ব **caveat**: সব fix literature-নির্দেশিত hypothesis, কিছুই বাস্তবায়ন/পরীক্ষা করা
হয়নি।

এই রিপোর্টের প্রতিটা সংখ্যা group report 01–09 থেকে হুবহু নেওয়া বা তাদের রিপোর্ট করা derived হিসাব — কোনো নতুন সংখ্যা

এখানে আবিষ্কার করা হয়নি। Verifier (08)-এর ধরা ৩টা ভুল সংশোধন করা হয়েছে, ১টা unverifiable claim provenance-সহ চিহ্নিত করা হয়েছে।